

EduPulse

Student Early Warning System

Technical Documentation & Data Science Report

Based on notebook: Edupulse_Update (18).ipynb

Project scope: Business Understanding -> Data Wrangling -> EDA -> Feature Engineering -> Machine Learning ->
Early Warning -> Deployment -> A/B Testing

Daftar Isi

1. 1. Executive Summary
2. 2. Business Understanding
3. 3. Data Gathering & Data Assessment
4. 4. Data Cleaning
5. 5. Exploratory Data Analysis (EDA)
6. 6. Feature Engineering
7. 7. Model Development & Validation
8. 8. Final Model & Early Warning Evaluation
9. 9. Model Export & Prediction Function
10. 10. A/B Testing
11. 11. Conclusion & Recommendation
12. 12. Appendix

Catatan: Angka dan temuan pada laporan ini dirangkum dari notebook Edupulse_Update (18) tanpa menambahkan klaim performa di luar hasil yang tercatat pada notebook.

1. Executive Summary

EduPulse adalah sistem early warning akademik berbasis data yang dirancang untuk memprediksi nilai Final Exam siswa menggunakan indikator kehadiran, hasil internal test, nilai assignment, dan kebiasaan belajar. Hasil prediksi kemudian diterjemahkan menjadi Risk Level untuk membantu proses monitoring dan identifikasi siswa yang membutuhkan perhatian lebih awal.

Tujuan Utama

Memprediksi nilai ujian akhir siswa sebelum hasil ujian tersedia, kemudian menggunakan hasil prediksi sebagai informasi pendukung untuk early warning akademik.

Komponen	Hasil Utama
Dataset	2.000 siswa, 7 kolom awal
Target	Final Exam Marks (out of 100)
Training / Testing	1.600 / 400 data
Validasi	5-Fold Cross Validation
Model final	Linear Regression
CV RMSE final	4,577
Test MAE / RMSE / R2	3,675 / 4,618 / 0,830
Early Warning accuracy	89% (classification; bukan regression accuracy)
At Risk recall	94% (245 dari 261 siswa At Risk teridentifikasi)
Deployment artifact	edupulse_model_final.joblib + predict.py
A/B Testing	Simulasi metodologi; bukan bukti efektivitas aktual

2. Business Understanding

2.1 Business Problem & Needs

Sekolah membutuhkan pendekatan berbasis data untuk memperkirakan performa ujian akhir dan mengenali siswa yang berpotensi memiliki risiko akademik sebelum hasil ujian akhir diperoleh. Monitoring manual dapat menjadi kurang efisien ketika jumlah siswa besar dan banyak indikator harus diperhatikan secara bersamaan.

2.2 Business Questions

1. Bagaimana hubungan antara kehadiran, hasil tes internal, nilai tugas, dan kebiasaan belajar dengan nilai Final Exam siswa?
2. Faktor akademik dan kebiasaan belajar apa saja yang paling informatif untuk digunakan dalam memprediksi nilai Final Exam?
3. Model Machine Learning dan konfigurasi fitur seperti apa yang sesuai untuk mendukung EduPulse sebagai early warning system akademik?

2.3 Proposed Solution & Output

EduPulse menggunakan model regresi untuk memprediksi Final Exam. Hasil prediksi dikonversi menjadi kategori risiko menggunakan threshold operasional: High Risk < 70, Medium Risk 70 hingga < 80, dan Low Risk >= 80. Output utama adalah Predicted Final Exam Score dan Risk Level.

3. Data Gathering & Data Assessment

Dataset yang digunakan adalah Final_Marks_Data.csv, diperoleh dari Kaggle melalui Student Academic Performance Dataset oleh Sonal Shinde. Notebook mencatat lisensi CC0: Public Domain.

Sumber dataset: [Kaggle - Student Academic Performance Dataset](#)

3.1 Struktur Dataset

Kolom	Peran / Skala
Student_ID	Identitas siswa
Attendance (%)	0-100
Internal Test 1 (out of 40)	18-40 pada dataset
Internal Test 2 (out of 40)	16-40 pada dataset
Assignment Score (out of 10)	4-10 pada dataset
Daily Study Hours	1-5 jam
Final Exam Marks (out of 100)	Target; 25-100

3.2 Hasil Assessment

Pemeriksaan	Hasil	Implikasi
Ukuran	2.000 baris x 7 kolom	Cukup untuk EDA dan pemodelan yang dilakukan
Tipe data	1 object (Student_ID), 6 int64	Variabel akademik dan target sudah numerik
Missing value	0 pada 7 kolom	Tidak perlu imputasi / penghapusan baris
Duplicate	0	Seluruh 2.000 observasi dipertahankan
Unique values	Student_ID 2.000; Final Exam 66; Assignment 7; Study Hours 5	Variasi fitur dapat dianalisis lebih lanjut
Rentang	Seluruh variabel dalam rentang valid	Tidak ditemukan nilai di luar batas valid

Statistik Final Exam: mean 64,855; std 11,341; Q1 58; median 65; Q3 73; min 25; max 100.

4. Data Cleaning

Tahap Data Cleaning pada notebook berfokus pada konsistensi struktur, validasi nilai, duplicate check, penilaian outlier, dan verifikasi akhir. Dataset tidak diperlakukan sebagai data yang harus “dipaksa” berubah apabila tidak ditemukan kesalahan data.

4.1 Pembersihan dan Validasi

Langkah	Hasil	Keputusan
Standardisasi nama kolom	student_id, attendance, internal_test_1, internal_test_2, assignment_score, daily_study_hours, final_exam	Digunakan untuk konsistensi analisis
Validasi tipe data	1 object + 6 numerik	Tidak perlu konversi tambahan
Duplicate check	0 duplicate	Semua observasi dipertahankan
Outlier IQR	Attendance 10; Test 1 8; Test 2 1; Assignment 79; Study Hours 3; Final Exam 7	Tidak dihapus karena masih berada pada rentang akademik yang valid
Verifikasi akhir	2.000 x 7; 0 missing; 0 duplicate	Data siap untuk EDA dan modeling

Keputusan penting terkait outlier

Outlier terdeteksi secara statistik, terutama pada assignment_score (79 data), tetapi nilai tersebut masih berada dalam rentang valid pada dataset. Karena tidak ditemukan indikasi kesalahan input, observasi dipertahankan.

5. Exploratory Data Analysis (EDA)


5.1 Statistik Deskriptif & Distribusi

Variabel	Mean	Median	Min	Max
Attendance	84,89	85	52	100
Internal Test 1	32,12	32	18	40
Internal Test 2	32,46	33	16	40
Assignment	7,51	8	4	10
Daily Study Hours	2,82	3	1	5
Final Exam	64,86	65	25	100

Sebanyak 50% nilai Final Exam berada pada rentang 58-73. Distribusi Final Exam memiliki 66 nilai unik dan menunjukkan variasi performa siswa pada rentang 25-100.

5.2 Hubungan dengan Final Exam

Fitur	Korelasi dengan Final Exam
Attendance	0,7256
Internal Test 2	0,6910
Internal Test 1	0,6892
Assignment	0,6694
Daily Study Hours	0,4129



Gambar 1. Korelasi indikator akademik dengan Final Exam. Sumber angka: notebook Edupulse_Update (18).

Evidence

Korelasi Attendance 0,7256; Internal Test 2 0,6910; Internal Test 1 0,6892; Assignment 0,6694; Daily Study Hours 0,4129.

Trend Analysis

Seluruh hubungan bernilai positif. Attendance memiliki korelasi individual tertinggi; Daily Study Hours memiliki korelasi individual terendah.

Actionable Insight

Variabel-variabel tersebut digunakan sebagai kandidat informasi untuk pemodelan dan early warning. Temuan EDA bersifat observasional dan tidak menyatakan hubungan sebab-akibat.

5.3 Profil Siswa Berdasarkan Performa

Kelompok	Attendance	Internal Test 1	Internal Test 2	Assignment	Study Hours	Final Exam
Low	78,08%	70,46	71,43	66,26	2,53	50,88
High	92,28%	90,20	91,64	83,62	3,14	79,55
Diferensial High-Low	+14,20 pp	+19,74	+20,21	+17,36	+0,61 jam	+28,67

Profiling menunjukkan pola deskriptif yang konsisten: kelompok dengan performa lebih tinggi memiliki rata-rata indikator akademik dan Final Exam yang lebih tinggi. Pola ini digunakan sebagai konteks untuk early warning, bukan sebagai bukti kausal.

5.4 Rescaling

Internal Test 1, Internal Test 2, dan Assignment dikonversi ke skala 0-100 melalui `internal_test_1_pct`, `internal_test_2_pct`, dan `assignment_pct`. Rescaling menyamakan skala representasi tanpa mengubah pola korelasi terhadap Final Exam.

6. Feature Engineering

Fitur	Mean	Std	Correlation dengan Final Exam
academic_average	78,84	8,74	0,8584
assessment_average	80,73	9,03	0,8683

academic_average dibentuk dari internal_test_1_pct, internal_test_2_pct, dan assignment_pct.

assessment_average dibentuk dari dua internal test yang sudah dinormalisasi. Kedua fitur tidak memiliki missing value.

Interpretasi feature engineering

Korelasi fitur agregat lebih tinggi daripada fitur individual, tetapi korelasi saja tidak cukup untuk menjadikan fitur agregat sebagai fitur final. Dampak terhadap performa model tetap perlu dibuktikan melalui evaluasi pemodelan.

7. Model Development & Validation

Data dibagi menjadi 1.600 data training dan 400 data testing menggunakan random_state=42. Evaluasi model menggunakan MAE, RMSE, dan R2. Cross validation menggunakan 5-Fold KFold dengan shuffle=True dan random_state=42.

7.1 Perbandingan Model pada Test Set

Model	MAE	RMSE	R2
Random Forest	4,151	5,234	0,781
Gradient Boosting	3,737	4,786	0,817
Decision Tree	4,741	5,965	0,716

7.2 Cross Validation

Model	MAE	Std MAE	RMSE	Std RMSE	R2	Std R2
Linear Regression	3,606	0,094	4,577	0,122	0,837	0,007
Random Forest	4,052	0,059	5,137	0,091	0,795	0,006
Gradient Boosting	3,883	0,082	4,902	0,115	0,814	0,006

7.3 Learning Curve

Indikator	Nilai
Ukuran training terbesar	1.280
Training RMSE terakhir	4,567
Validation RMSE terakhir	4,577

Gap RMSE terakhir	0,010
-------------------	-------


Kurva training dan validation mendekat pada akhir proses dengan gap RMSE sebesar 0,010, sehingga tidak tampak indikasi overfitting yang besar pada hasil learning curve tersebut.

7.4 Hyperparameter Tuning

Model	Best Parameters	Tuned CV RMSE
Random Forest	max_depth=10; min_samples_leaf=2; min_samples_split=5; n_estimators=300	4,988
Gradient Boosting	learning_rate=0,05; max_depth=2; min_samples_split=2; n_estimators=200	4,833
Decision Tree	max_depth=8; min_samples_leaf=4; min_samples_split=10	5,691

7.5 Model Selection

Model / Kondisi	CV RMSE
Linear Regression	4,577
Gradient Boosting Tuned	4,833
Random Forest Tuned	4,988
Decision Tree Tuned	5,691



Gambar 2. Perbandingan CV RMSE yang digunakan dalam model selection.

Berdasarkan 5-Fold Cross Validation, Linear Regression digunakan sebagai model final. Hasil test-set dipakai sebagai evaluasi akhir dan bukan sebagai dasar pemilihan model.

8. Final Model & Early Warning Evaluation

8.1 Evaluasi Final Model

Metrik	Nilai
MAE	3,675
RMSE	4,618
R2	0,830
Jumlah test set	400

R2 sebesar 0,830 berarti pada data testing, model menjelaskan sekitar 83,0% variasi nilai target berdasarkan evaluasi R2 yang digunakan dalam notebook. MAE dan RMSE menunjukkan besar error prediksi pada skala nilai Final Exam.

8.2 Early Warning Risk Analysis

Risk Level	Threshold Predicted Final	Jumlah	Proporsi Test Set
High Risk	< 70	275	68,75%
Medium Risk	70 hingga < 80	98	24,50%
Low Risk	>= 80	27	6,75%
Risk Group	Mean Actual Final	Min	Max
High Risk	59,55	31	80
Medium Risk	74,87	62	86
Low Risk	82,67	71	94

8.3 Classification Evaluation

Metric	At Risk	Not At Risk
Precision	0,89	0,87
Recall	0,94	0,78
F1-score	0,91	0,83
Support	261	139

Accuracy klasifikasi Early Warning adalah 89%. Confusion matrix: 245 True Positive, 16 False Negative, 30 False Positive, dan 109 True Negative.

Pembedaan metrik

Angka 89% adalah accuracy untuk klasifikasi Early Warning setelah thresholding prediksi regresi. Angka tersebut bukan regression accuracy. Kinerja regresi dilaporkan dengan MAE, RMSE, dan R2.

9. Model Export & Prediction Function

9.1 Model Package

Field	Nilai
Model	Linear Regression
Version	final_1
Deployment features	attendance, quiz_1_score_pct, quiz_2_score_pct, assignment_pct, daily_study_hours
Risk thresholds	High Risk 70; Medium Risk 80
Evaluation	MAE 3,6749513; RMSE 4,6179439; R2 0,8297242; CV RMSE 4,5769153
Artifact	edupulse_model_final.joblib

Notebook menggunakan `internal_test_1_pct` dan `internal_test_2_pct` dalam representasi feature analitis. Pada interface deployment, fitur tersebut dipetakan ke `quiz_1_score_pct` dan `quiz_2_score_pct` agar tetap kompatibel dengan `predict.py` yang digunakan aplikasi.

9.2 Prediction Function

`predict.py` memuat model package, menerima input `attendance`, `quiz_1_score_pct`, `quiz_2_score_pct`, `assignment_pct`, dan `daily_study_hours`, lalu mengembalikan `predicted_score` dan `risk`. Uji fungsi pada notebook berhasil menghasilkan contoh prediksi: 70,84 (Medium Risk), 15,55 (High Risk), 69,85 (High Risk), dan 83,83 (Low Risk), tanpa `UserWarning`.

Deployment status

Model package berhasil diverifikasi dan fungsi `predict_student()` berhasil menerima input serta mengembalikan score dan risk sesuai threshold yang ditentukan.

10. A/B Testing


Notebook menyiapkan A/B Testing sebagai validasi statistik untuk insight/rekomendasi. Karena belum terdapat eksperimen intervensi nyata pada pengguna, bagian ini menggunakan data simulasi untuk mendemonstrasikan metodologi.

10.1 Desain Eksperimen

Komponen	Detail
Group	Control dan Treatment
Assignment	Random assignment pada data simulasi
Outcome	<code>outcome_score</code>
Statistical test	Independent t-test
Effect size	Cohen's d
Alpha	0,05

10.2 Hasil Simulasi

Group	N	Mean	Std
Control	199	65,07	11,38
Treatment	201	67,74	11,47
Difference	-	+2,66	-
Analisis		Hasil	
T-statistic		2,3331	
p-value		0,0201	
Alpha		0,05	
Cohen's d		0,2333	



Gambar 3. Rata-rata outcome pada A/B Testing simulasi.

Batasan A/B Testing

p-value 0,0201 dan Cohen's d 0,2333 hanya mendeskripsikan data simulasi. Outcome dan simulated treatment effect dibuat secara sintetis, sehingga hasil tersebut tidak boleh dipakai sebagai bukti bahwa rekomendasi EduPulse meningkatkan performa siswa pada pengguna nyata.

11. Conclusion & Recommendation

11.1 Jawaban Business Question 1

EDA menunjukkan hubungan positif antara Attendance, Internal Test 1, Internal Test 2, Assignment, dan Daily Study Hours dengan Final Exam. Korelasi individual berkisar dari 0,4129 hingga 0,7256, dengan Attendance

sebagai korelasi individual tertinggi. Profiling juga menunjukkan rata-rata Final Exam meningkat dari 50,88 pada Low Performance menjadi 79,55 pada High Performance.

11.2 Jawaban Business Question 2

Fitur agregat menunjukkan korelasi lebih tinggi: `academic_average` 0,8584 dan `assessment_average` 0,8683. Namun, model final mempertahankan lima fitur utama: `attendance`, `internal_test_1_pct`, `internal_test_2_pct`, `assignment_pct`, `daily_study_hours`. Fitur agregat diposisikan sebagai kandidat eksperimen lanjutan dan bukan otomatis menjadi fitur final.

11.3 Jawaban Business Question 3

Linear Regression digunakan sebagai model final setelah perbandingan cross validation dan tuning. CV RMSE tercatat 4,577. Evaluasi testing menghasilkan MAE 3,675, RMSE 4,618, dan R2 0,830. Untuk Early Warning classification, accuracy 89% dengan At Risk recall 94% (245 dari 261 teridentifikasi).

11.4 Rekomendasi Action Item

- Meningkatkan monitoring siswa menggunakan Predicted Final Exam, Risk Level, dan indikator akademik sebagai informasi pendukung.
- Mengembangkan rekomendasi yang lebih spesifik berdasarkan kondisi `attendance`, `internal test`, `assignment`, dan `daily study hours`.
- Menguji kembali `academic_average` dan `assessment_average` pada eksperimen pemodelan berikutnya.
- Melakukan evaluasi model secara berkala menggunakan data siswa terbaru dan meninjau kembali threshold risiko.
- Melakukan validasi menggunakan data operasional dari institusi pendidikan.
- Melakukan A/B Testing aktual pada pengguna nyata dengan random assignment, intervensi nyata, dan pengukuran outcome setelah periode intervensi.

Kesimpulan pengembangan

Notebook telah mencakup alur end-to-end dari business understanding sampai deployment. Model final dan fungsi prediksi telah diuji, sedangkan A/B Testing masih berada pada tahap demonstrasi metodologi melalui simulasi.

12. Appendix

A. Key Metrics Reference

Area	Metric	Value
EDA	Attendance correlation	0,7256
EDA	Internal Test 1 correlation	0,6892
EDA	Internal Test 2 correlation	0,6910
EDA	Assignment correlation	0,6694
EDA	Daily Study Hours correlation	0,4129
Feature Engineering	<code>academic_average</code> correlation	0,8584
Feature Engineering	<code>assessment_average</code> correlation	0,8683
Final Model	CV RMSE	4,5769

Final Model	Test MAE	3,6750
Final Model	Test RMSE	4,6179
Final Model	Test R2	0,8297
Early Warning	Accuracy	89%
Early Warning	At Risk recall	94%
A/B Simulation	p-value	0,0201
A/B Simulation	Cohen's d	0,2333

B. Reproducibility Notes

Train/test split menggunakan `random_state=42`. Cross validation menggunakan `KFold(n_splits=5, shuffle=True, random_state=42)`. Model final yang digunakan adalah Linear Regression. Artifact deployment yang diverifikasi adalah `edupulse_model_final.joblib` dan fungsi aplikasi adalah `predict.py`.

Dokumen ini merupakan ringkasan teknis berbasis notebook `Edupulse_Update (18).ipynb` dan dimaksudkan sebagai dokumentasi pendamping untuk proyek EduPulse.